

PRÁCTICA 1: ESTADÍSTICA DESCRIPTIVA

Objetivos

- Iniciarse en el manejo del sistema estadístico STATGRAPHICS.
- Realizar un estudio descriptivo de conjuntos de datos recogidos de distintas variables aleatorias.

Ficheros de datos a utilizar: Mundo 2013.sgd, Salarios.sgd.

1.1 ENTRADA AL SISTEMA

Al abrir el programa STATGRAPHICS, se muestra una ventana con las barras de menús y de herramientas en la parte superior y siete pequeños iconos en el lateral izquierdo, correspondientes a sendas ventanas.

La ventana <Libro de datos> permite utilizar el fichero de datos con el que se va a trabajar. Este fichero puede cargarse si ya está creado o, directamente, crearlo en esta ventana. Cada columna recogerá los datos de una variable diferente.

1.2 VISTA DE UN FICHERO DE DATOS

Abrir el fichero de datos **Mundo 2013.sgd**. Para ello, usar el menú **Archivo > Abrir > Abrir fuente datos > Archivo de Datos STATGRAPHICS** o bien, pulsar el icono <Abrir archivo de datos>, cuarto por la izquierda en la barra de herramientas.

El fichero contiene las variables siguientes:

- **País:** Nombre del país al que corresponden los datos.
- **Continente:** África, América, Asia, Europa u Oceanía.
- **Superficie:** superficie de un país, en miles de kilómetros cuadrados.
- **Población:** población de un país, en millones de habitantes.
- **Mortalidad infantil:** número de fallecidos menores de 1 año , por cada 1000 nacidos vivos en dicho año en un país .
- **Alfabetización:** porcentaje de alfabetizados en un país de personas mayores de 9 años.
- **PIBpc:** producto interior bruto per cápita de un país.


Cada variable aparece como una columna con su nombre en la cabecera y un dato en cada celda, como en una hoja de cálculo. Para observar las características de una variable, pulsar dos veces en su nombre.

1.3 GRABAR LOS RESULTADOS DE UNA SESIÓN DE TRABAJO

Cuando se ejecuta un cierto procedimiento, los resultados aparecen en varias ventanas. Todas las ventanas de resultados de un mismo procedimiento se pueden guardar a la vez usando el botón derecho del ratón y seleccionando “Copiar Análisis a StatReporter”.

En la ventana StatReporter (icono cuarto de los que aparecen en el lateral izquierdo) se pueden añadir los comentarios que se deseen y guardar posteriormente desde el menú Archivo > Guardar > Guardar StatReporter. Se va a guardar en formato rtf, y este archivo se puede abrir con Word.

También se puede grabar todo lo realizado usando la opción de menú Archivo > Guardar > Guardar StatFolio y se grabará un fichero con extensión .sgp. En este formato no se pueden añadir comentarios.



PROBLEMA 1: ANÁLISIS DE DATOS QUE PROVIENEN DE DISTINTOS PAÍSES

Para realizar un estudio estadístico de un conjunto de datos de una variable lo primero que hay que saber es si la variable de la que provienen es cualitativa, cuantitativa discreta o cuantitativa continua.

El procedimiento de Statgraphics que tendremos que usar para hacer este estudio estadístico viene determinado, además, por el hecho de si tenemos pocos o muchos valores distintos entre los datos.

Cualitativas o Discretas : Describir/Datos Categóricos/Un factor/Tabulación

- Tabla de frecuencias - Diagrama de rectángulos - Diagrama de barras - Diagrama de sectores

Discretas: Medidas descriptivas, cuartiles y percentiles : Describir/Datos Numéricos/Análisis de una variable

Continuas (muchos datos distintos) : Describir/Datos Numéricos/Análisis de una variable


- Tabla de frecuencias - Medidas descriptivas - Cuartiles y Percentiles – Histograma
- Polígono de frecuencias - Gráfico Caja y Bigotes (Box-Plot)

1.4 TABLAS DE FRECUENCIAS Y GRÁFICOS

1.4.1 CONJUNTOS DE DATOS CON POCOS VALORES DISTINTOS


Vamos a generar la tabla de frecuencias y el diagrama de barras de la variable *Continente*. Esta variable es un tipo de variable que se llama **variable cualitativa**: no toma valores numéricos sino “cualidades”. Otros ejemplos de este tipo de variables pueden ser *Color de pelo de una persona* o *Satisfacción de un alumno frente al funcionamiento del CIC*.

- a) Usar el menú **Describir > Datos Categóricos > Un Factor > Tabulación** y elegir la variable deseada.



- b) En el cuadro de diálogo que aparece, **dejar las opciones que aparecen marcadas por defecto**. Se abre una ventana titulada **<Tabulación - Continente>** con varios paneles o ventanas.


- La tabla de frecuencias de la variable figura en el panel **<Tabla de Frecuencia para Continente>**. Copiarla a continuación o guardar en StatReporter.
- Modificar el diagrama de barras, que figura en otra de las ventanas, para que dichas barras aparezcan en vertical. Para ello, pinchar en el panel con el botón derecho, seleccionar **<Opciones de Ventana>** y activar la opción pertinente. Copiar o guardar en StatReporter el gráfico



1.4.2 CONJUNTOS DE DATOS CON MUCHOS VALORES DISTINTOS

Vamos a generar la tabla de frecuencias y el histograma de la variable *Alfabetización*. Cuando hay muchos valores distintos (más de 20, como ocurre en este caso), STATGRAPHICS agrupa estos datos en intervalos de la misma amplitud y obtiene la tabla de frecuencias y el histograma. Para ello:

- a) Usar el menú **Describir > Datos Numéricos > Análisis de Una Variable** y elegir la variable **Alfabetización**.




- b) En la siguiente ventana que se abre, marcar **<Resumen del Análisis>**, **<Resumen Estadístico>**, **<Tabla de Frecuencias>** e **<Histograma>**.


- En el panel **<Tabla de Frecuencias para Alfabetización>** aparece la tabla de frecuencias de la variable en intervalos de la misma longitud.

Ajustar el número de clases a 9, el Extremo inferior = 10 y el Extremo superior = 100. Para ello, **pinchar en el panel con el botón derecho, seleccionar <Opciones de Ventana>** y modificar las opciones pertinentes. STATGRAPHICS agrupa los datos en intervalos de la forma $(a, b]$. Copiar o guardar en StatReporter el resultado.

- Copiar o guardar en StatReporter el histograma de la variable agrupada en los mismos intervalos definidos en el punto anterior, que aparece en el panel **<Histograma>**.



- c) Realizar también el histograma para la variable Mortalidad Infantil, usando como Extremo inferior = 0, Extremo superior = 200 y 10 intervalos. Copiarlo también.



1.5 MEDIDAS DE CENTRALIZACIÓN (O POSICIÓN), DISPERSIÓN Y FORMA

Vamos a calcular las medidas de posición, dispersión y asimetría de *Alfabetización* y de *Mortalidad infantil*.

IMPORTANTE: Para calcular medidas de un conjunto de datos, STATGRAPHICS usa el procedimiento **Describir > Datos Numéricos > Análisis de Una Variable > Resumen Estadístico**, **TANTO SI EL CONJUNTO DE DATOS TIENE POCOS VALORES DISTINTOS COMO SI TIENE MUCHOS**.

1.5.1 Medidas de las variables *Alfabetización* y *Mortalidad Infantil*.

Volver a seleccionar **Describir > Datos Numéricos > Análisis de Una Variable** y después elegir **<Resumen Estadístico para Alfabetización>** para obtener las medidas de centralización, dispersión y asimetría de la variable *Alfabetización*. (También se puede hacer lo mismo así: desde la ventana de resultados que se tiene abierta, con el botón derecho del ratón elegir **<Tablas y gráficos>** y después seleccionar **<Resumen Estadístico para Alfabetización>**).

Calcular solamente las medidas que se piden para rellenar la tabla que está más adelante. Para ello, pinchar en el panel con el botón derecho y seleccionar **<Opciones de Ventana>**.

Opciones Resumen Estadístico			
☒ Promedio	☒ Desviación Estándar	☐ Sbi	☐ 5/6 Sextil
☒ Mediana	☒ Coef. de Variación	☒ Mínimo	☐ Rango Intersextil
☒ Moda	☐ Coeficiente de Gini	☒ Máximo	☒ Sesgo
☐ Media Geométrica	☐ Error Estándar	☒ Rango	☐ Sesgo Estd.
☐ Media Armónica	☐ Desviación Estándar Geométrica	☒ Cuartil Inferior	☐ Curtosis
☐ Media Recortada 5 %	☐ Sigma Winsorizada	☒ Cuartil Superior	☐ Curtosis Estd.
☐ Media Winsorizada	☐ Desviación Media Absoluta	☒ Rango Intercuartil	☐ Suma
☒ Varianza	☐ DAM	☐ 1/6 Sextil	☐ Suma de Cuadrados
Aceptar Cancelar Todos Ayuda			

Repetir el proceso para la variable *Mortalidad Infantil* y copiar los resultados. Para ello, pulsando el botón derecho del ratón, seleccionar **Diálogo de Captura** y seleccionar dicha variable. **Al hacerlo, se actualiza el contenido de todos los paneles para la nueva variable.**

Medida	<i>Alfabetización</i>	<i>Mortalidad infantil</i>
Promedio (Media aritmética)	77,1935	46,9873
Mediana	85,0	33,0
Moda	--	4,0
Varianza (Cuasivarianza)	525,131	1578,36
Desviación Estándar (Cuasidesviación típica)	22,9157	39,7286
Coefficiente de Variación (de Pearson)	29,6861%	84,5518%
Mínimo	15,0	3,0
Máximo	100,0	192,0
Cuartil Inferior (Primer cuartil Q ₁)	58,0	14,0
Cuartil Superior (Tercer cuartil Q ₃)	97,0	72,0
Coefficiente de asimetría de Fisher (Sesgo)	-0,798495	0,884276

1.5.2 Percentiles de las variables *Alfabetización* y *Mortalidad Infantil*.

Calcular los percentiles de la variable *Alfabetización* indicados en la tabla siguiente. Para ello, usar el panel <Percentiles para Alfabetización>, que contiene algunos percentiles. Para activar este panel, con el botón derecho del ratón, seleccionar <Tablas y gráficas> y activar **Percentiles**.

Por defecto, aparecen una serie de percentiles. Con el botón derecho del ratón, elegir <Opciones de ventana> y calcular los percentiles deseados.

Repetir los cálculos para la variable *Mortalidad Infantil*.

Percentil	<i>Alfabetización</i>	<i>Mortalidad infantil</i>
P ₁₂	42.0	5.0
P ₇₅	97.0	72.0
P ₈₈	99.0	99.0

1.5.3 Interpretación de resultados para la variable *Alfabetización y Mortalidad Infantil*:

A la vista de las tablas anteriores, contestar a las preguntas siguientes:

- La alfabetización media en los países del mundo es **77.1935 Promedio (Media aritmética)**
- La cuarta parte de los países tiene una alfabetización menor o igual que 58%
58% Cuartil Inferior (Primer cuartil Q_1) , lo mismo que decir el 75% tienen una alfabetización mayor o igual (o de al menos) .
- El 25% de los países tienen una alfabetización de al menos:
97% Percentil 75
- El menor porcentaje de alfabetización es: **15,0 Mínimo**
Corresponde al país: **Níger (mirado en la tabla de datos inicial ordenado por ascendente según la alfabetización)**
- Aproximadamente, ¿cuántos países hay que tengan una alfabetización entre el 58% y el 97%?:
121, según la tabla de frecuencias , consiguiendo un intervalo desde 58 hasta 97 o la suma de varios intervalos , también se puede hacer $p_{75}-p_{25}$ (ya que sabemos que se corresponden con el 97% y 25%) y te da el porcentaje de los datos que están entre ambos valores y sabiendo el número total de valores calculas los que están en medio.
- La mortalidad infantil más frecuente es **4.0 Moda**
- La mitad los países tiene una mortalidad infantil mayor o igual que **33.0 Percentil 50 o Mediana**
- El 88% de los países tiene una mortalidad infantil de al menos **5,0 Percentil 12**
Ya que el percentil deja por debajo el x% de los datos
- El mayor valor de mortalidad infantil es : **192, 0 Máximo**
Corresponde al país: **Angola (mirado en la tabla de datos inicial ordenado por descendente según la mortalidad infantil)**
- Aproximadamente, ¿cuántos países hay que tengan una mortalidad infantil entre 5% y el 72%?: **Sabemos que el P_{12} es 5% y el P_{75} es 72% , así $p_{75}-p_{12} = 75-12 = 63\%$ de los países , 63 % de los países cuantos países hay ¿? >>> de 157: $157 \times 0,63 = 98,91 = 99$ países**

Justificar qué variable tiene mayor dispersión en los datos:

La variable mas dispersa es la mortalidad infantil con un coeficiente de variación **84,5518%**

Justificar qué tipo de asimetría tiene cada variable:

La variable alfabetización tiene una distribución asimétrica hacia la izquierda ,es decir ,un sesgo negativo y alejado de 0 .

La variable mortalidad infantil tiene una distribución asimétrica hacia la derecha, es decir, un sesgo positivo.


Justificar qué variable es más asimétrica:

La variable más asimétrica será la que tenga un sesgo más alejado del 0 en valor absoluto, en este caso, será la variable mortalidad infantil


1.6 DIAGRAMA DE CAJA Y BIGOTES (BOX-PLOT) PARA LAS VARIABLES *ALFABETIZACIÓN* Y *MORTALIDAD INFANTIL*.

Vamos a obtener el Box-Plot de la variable *Alfabetización*. El diagrama de caja y bigotes de una variable es un gráfico que utiliza varias de sus medidas descriptivas y revela sus valores atípicos.

Para obtener este diagrama, con el botón derecho del ratón, seleccionar <Tablas y gráficos> y activar **Gráfico de caja y bigotes**.



Obtener el diagrama de caja de la variable *Mortalidad Infantil*.



1.7 ESTUDIO DE UN SUBCONJUNTO DE DATOS DE UNA VARIABLE

En este apartado vamos a estudiar la variable *Alfabetización* sólo para los datos de países de Europa y para los datos de los países de África. Para ello, usar el menú **Describir > Datos Numéricos > Análisis de Una Variable**, elegir la variable *Alfabetización* y en **Selección**, poner **Continente = “Europa”** (son necesarias las comillas). Rellenar la siguiente tabla. Repetir el proceso para la variable *Alfabetización* y **Continente = “África”** (son necesarias las comillas y el acento).

	Promedio (Media)	Mediana	Cuartil tercero	Coefficiente de variación
Europa	97,6471	98,0	99,0	3,24712%
África	53,4444	48,0	67,0	33,5272%
Todos los países	77,1935	85	97,0	29,6861%


- Comenta las diferencias que se observan entre la Alfabetización en Europa y en África.

En Europa la Media es mucho más alta así que de media Europa esta mucho más alfabetizada , especialmente se ve en el tercer cuartil en donde vemos que para alcanzar el 75% en el ranking de alfabetización este solo se alcanza a con un 99 % en Europa de alfabetización mientras que en Africa solo se necesita 67% , también vemos que en los diversos países de Europa es mas homogénea la tasa de alfabetización a deferencia de África esto se ve en el coeficiente de variación.

- Comenta las diferencias entre la Alfabetización en Europa y la Alfabetización si consideramos todos los países.

Pues vemos cosas similares mientras que Europa es mucho más elevada y uniforme en el mundo en total aunque es más elevada que en África al incluir a zonas desarrolladas como Norteamérica y Europa muestra una gran disparidad entre países como es lógico.

Obtener el gráfico de caja y bigotes para los datos de la variable *Alfabetización* sólo para países europeos.



Identificar a qué países corresponden los datos atípicos de la variable *Alfabetización* en Europa y dar su valor:


Para las filas 102 , 63 , 123 (que se muestran al pinchar en los cuadrados que representan los datos atípicos) que se corresponden con Bosnia , Portugal y Albania respectivamente.

PROBLEMA 2: ANÁLISIS DE SALARIOS

Cargar el fichero **Salarios.sgd**.

En la columna **Salario** figuran los salarios de los trabajadores de la empresa CIENSA, expresados en euros mensuales. Con estos datos, se pide:

- a) Representar la variable **Salario** mediante un diagrama de barras o un histograma, según proceda, ajustar los valores mínimo y máximo del histograma y el número de intervalos del mismo para que el gráfico sea más claro.



- b) Obtener sus principales medidas de posición, dispersión y asimetría.

Medidas de posición		Medidas de dispersión	
Media	595,675	Varianza	2983,23
Mediana	594,0	Desviación típica	54,619
Moda	600,0	Coef. de variación	9,16926%
Mínimo	480,0	Rango	240,0
Máximo	720,0	Rango Intercuartílico	78,0
Primer cuartil	552,0	Medida de forma	Curtosis -0,504123
Tercer cuartil	630,0	Coef. de asimetría de Fisher (Sesgo)	0,217727

c) Interpretar las siguientes medidas en términos de la variable Salario.

Media : 595,675\$, la media de los que todo el mundo cobra.

Mediana : 594,0\$, salario entre el 50% que más cobra y el 50% que menos lo hace.

Moda: 600\$ es el salario más común.

Mínimo y máximo: Salario mínimo 480\$ y máximo 720\$ que cobra un empleado de la empresa

Primer cuartil: hasta el 25% de la gente esta por debajo de cobrar 552\$

Tercer cuartil: hasta el 75% de la gente cobra menos de 630\$


Coefficiente de variación: al ser bajo de un 9,2% los salarios serán muy similares

Coefficiente de asimetría de Fisher: La variable tiene una distribución asimétrica hacia la derecha, es decir, un sesgo positivo

c) Encontrar un salario tal que el 60% de los empleados cobren por lo menos esa cantidad mensual.

Buscamos entonces el percentil 40 , en donde el 60 % de los empleados cobrarán mas de esa cantidad , así el $P_{40} = 579,0$

d) En la columna **Salario con jefe** se ha añadido a los salarios de los trabajadores el salario del jefe, 16500 €/mes. STATGRAPHICS permite comparar las medidas y gráficos de varios conjuntos de datos. Para ello, usar el menú **Describir > Datos Numéricos > Análisis Múltiple Variable**.




Selecciona ambas variables, **Salario** y **Salario con jefe**, en Opciones de Análisis selecciona la opción **Todos los Datos**, y en la ventana de Tablas y Gráficos selecciona solamente **Resumen Estadístico**.

¿Cómo cambian las principales medidas si tenemos en cuenta el salario del jefe?

	Salario con jefe	Salario
Recuento	81	80
Promedio	792,025	595,675
Mediana	594,0	594,0
Moda	600,0	600,0
Varianza	3,12576E6	2983,23
Desviación Estándar	1767,98	54,619
Coefficiente de Variación	223,223%	9,16926%
La desviación estándar geométrica	1,46308	1,09587
Mínimo	480,0	480,0
Máximo	16500,0	720,0
Rango	16020,0	240,0
Cuartil Inferior	552,0	552,0
Cuartil Superior	630,0	630,0
Rango Intercuartílico	78,0	78,0
Sesgo	8,98696	0,217727


e) Dibujar los diagramas de caja y bigotes de las variables *Salario* y *Salario con jefe*



¿Qué diferencias se observan?

Que como vemos los salarios de los empleados se agrupan sin excepción alguna dentro de lo normal.


Sin embargo si añadimos el único dato del jefe con todos los del grupo veremos que se agrupan de forma muy pequeña los de los empleados porque vistos a escala masiva están muy agrupados , y luego un dato fuera de la norma el salario del jefe muchísimo mayor al resto.



f) A partir de la variable *Salario*, se quieren definir dos nuevas variables: *SalarioMas60*, que recoja una subida de 60 €/mes para cada empleado y *SalarioMas10porciento*, otra variable que recoja una subida del 10% para cada empleado. **PARA CREAR NUEVAS VARIABLES EN UN FICHERO DE DATOS** (hay que crearlas de una en una):

1. Ponerse en una columna vacía y pulsando el botón derecho del ratón, elegir la opción **Generar datos**.
2. Escribir la fórmula en la línea que pone **Expresión**. Para hacerlo, se puede usar los nombres de la lista **Variables** y los operadores predefinidos en la lista **Operadores**.

Una vez creadas, vamos a comparar las tres variables a la vez: Para ello, se puede usar el menú **Comparar > Varias muestras > Comparación de varias muestras** y marcar solamente **<Resumen Estadístico>** y **<Gráficos de caja y bigotes>**.



- Calcular las siguientes medidas para **Salario**, **SalarioMas60** y **SalarioMas10porciento**:

Métrica	Salario	SalarioMas60	SalarioMas10porciento
Número datos	80	80	80
Media	595,675	655,675	655,243
Mediana	594,0	654,0	653,4
Moda	600,0	660,0	660,0
Desviación Estándar	54,619	54,619	60,0809
Varianza	2983,23	2983,23	3609,71
Coefficiente de Variación	9,16926%	8,33019%	9,16926%
Mínimo	480,0	540,0	528,0
Máximo	720,0	780,0	792,0
Rango	240,0	240,0	264,0
Cuartil Inferior	552,0	612,0	607,2
Cuartil Superior	630,0	690,0	693,0
Rango Intercuartílico	78,0	78,0	85,8
Coefficiente asimetría de Fisher	0,217727	0,217727	0,217727

Medidas de posición:

Tanto al sumar una cantidad fija (+60) como al aplicar un porcentaje (+10%), todas las medidas de posición (mediana, moda, cuartiles, mínimo y máximo) se transforman de forma directa y lineal. Esto ocurre porque estas medidas simplemente indican dónde se ubican los datos; si toda la escala se desplaza o se estira, los puntos de posición lo hacen en la misma proporción exacta.

Relación entre la media de las tres variables:

La subida fija de 60 eleva la media exactamente en 60 unidades (de 595,67 a 655,67). La subida del 10% multiplica la media original por 1,10 (llegando a 655,24). En este caso particular, la media del aumento fijo es levemente mayor porque 60 es superior al 10% de la media original.

Medidas de dispersión:

Sumar una cantidad fija a todos los salarios no altera las medidas de dispersión (la desviación estándar, el rango y el rango intercuartílico se mantienen idénticos). Esto se debe a que la distancia absoluta entre el que más cobra y el que menos cobra no cambia. Por el contrario, un aumento porcentual sí incrementa la dispersión, ya que amplía la brecha absoluta entre los sueldos.

Relación entre las varianzas de las tres variables:

La varianza es inalterable ante sumas, por lo que el salario original y el de "+60" tienen exactamente la misma varianza (2983,23). Sin embargo, ante multiplicaciones (como el +10%). Es decir, la nueva varianza se obtiene multiplicando la original por el cuadrado del aumento ($1,10^2 = 1,21$), disparándose a 3609,71.

¿Qué sería preferible a la hora de subir salarios para que la dispersión sea menor?

Es preferible una **subida fija igual para todos**.

¿Por qué? Porque una subida fija mantiene intacta la dispersión absoluta entre los trabajadores (la desviación estándar y la varianza no cambian). Si se aplica una subida porcentual, los salarios más altos reciben un aumento mayor en dinero real que los salarios más bajos, lo que aumenta matemáticamente la desigualdad interna y, por tanto, incrementa la dispersión general de la plantilla.

- Dibuja a la vez los diagramas de Caja y Bigotes de las tres variables (*Salario*, *SalarioMas60* y *SalarioMas10porciento*).

