

PRÁCTICA 2: REGRESIÓN LINEAL

Objetivos

- Conocer distintos modelos de regresión para estudiar la relación entre dos variables.
- Interpretar y comparar los resultados obtenidos en diferentes ajustes.
- Conocer las capacidades de Statgraphics para construir modelos de regresión.

Ficheros de datos a utilizar: Mundo 2013.sgd.

2.1 ESTUDIO PARA DETERMINAR LA INFLUENCIA DE LA ALFABETIZACIÓN EN LA MORTALIDAD INFANTIL

En Statgraphics, abrir el fichero **Mundo 2013.sgd** (Archivo > Abrir > Abrir fuente de datos...), que contiene las variables siguientes:


- “País”: nombre del país al que corresponden los datos.
- “Continente”: África, América, Asia, Europa y Oceanía.
- “Superficie” en miles de km².
- “Población” en millones de habitantes.
- “Alfabetización”: número de alfabetizados cada 100 personas mayores de 9 años.
- “Mortalidad infantil”: número de fallecidos menores de 1 año cada 1000 nacidos vivos.
- “PIBpc”: Producto interior bruto per cápita.

2.1.1. AJUSTE DE UN MODELO DE REGRESIÓN LINEAL: RECTA DE REGRESIÓN

Vamos a estudiar la influencia de la alfabetización de un país en su mortalidad infantil usando un modelo lineal. Para ello:

1. Usar el menú **Relacionar > Modelos Reg. Simple > Regresión simple...**
2. En el cuadro de diálogo < **Regresión Simple**>, seleccionar la variable “*Mortalidad infantil*” como dependiente (Y) y la variable “*Alfabetización*” como independiente (X).
FUNDAMENTAL aquí decidir cuál de las variables es X y cuáles Y (no es conmutativo)
3. En el cuadro de diálogo < **Opciones Regresión Simple**>, marcar < **Lineal**> y marcar **Incluir constante**.
4. En el cuadro de diálogo < **Tablas y Gráficos**>, marcar < **Resumen del análisis**>, < **Pronósticos**> y < **Gráfico del Modelo Ajustado**>. Al aceptar, aparece una ventana con 3 paneles: uno con los datos numéricos del ajuste, otro con el diagrama de dispersión y otro para hacer predicciones.
5. Para aumentar la claridad del gráfico, pinchar en su panel con el botón derecho, seleccionar < **Opciones de ventana...**> y desactivar < **Límites de predicción**> y < **Límites de Confianza**>.

Dibujar un esquema del diagrama de dispersión con la recta de regresión. Copiar la ecuación del modelo ajustado, y los valores del coeficiente de correlación lineal, r , y el coeficiente de determinación R^2 .



Interpretar el coeficiente de correlación lineal y su signo. Interpretar también el coeficiente de determinación:

Si $r < 0$, la dependencia lineal es negativa, Indica que cuando X crece, la Y decrece (o al revés).

Esto significa que cuando una variable aumenta, la otra tiende a disminuir. En este caso: a mayor tasa de alfabetización, menor es la tasa de mortalidad infantil. Como el valor absoluto de $-0,757$ está bastante cerca de 1, podemos concluir que la relación lineal entre la alfabetización y la mortalidad infantil es fuerte.

Comprobar que $r^2 = R^2$ ¿Es coherente lo observado en la gráfica con los valores obtenidos para r y R^2 ?


¿ $r^2 = R^2$? , calculemos $r^2 = (-0,757921)^2 = 0,5744$ lo que equivale al resultado de mi R^2 o lo que es 57,4444%

Sí es coherente con lo observado en la gráfica, la inclinación descendente de la recta y de la nube de puntos confirma visualmente el signo negativo de la correlación además, la distancia o "grosor" de la nube de puntos alrededor de la línea refleja perfectamente que el ajuste es del 57,4444%.

2.1.2. IDENTIFICACIÓN DE DATOS EN EL DIAGRAMA DE DISPERSIÓN

Se puede identificar países en el diagrama de dispersión. Para ello:

1. Hacer doble clic en el gráfico para maximizarlo.
2. Usar el menú **Identificar > Marca...**
3. Seleccionar la variable deseada como etiqueta, en este caso “País” , poner la variable en **Identificar con** y pulsar el botón <OK>.
4. Pinchando ahora sobre un punto, aparece el nombre del país correspondiente. Identificar por este método 2 países alejados de la recta ajustada y otros 2 próximos a ella:



2.1.3. ESTIMACIONES PARA LA VARIABLE DEPENDIENTE “MORTALIDAD INFANTIL” USANDO LA RECTA DE REGRESIÓN OBTENIDA

Vamos a usar el modelo de regresión obtenido para estimar la mortalidad infantil en varios países, unos del conjunto de datos (para observar la calidad de la estimación) y otros desconocidos, para hacer predicciones. Para ello:

La opción que permite estimar valores de la variable Y, en este caso, “*Mortalidad infantil*” se ha seleccionado ya en el menú <Tablas y Gráficos> y eligiendo <Pronósticos>. En la ventana de resultados, con el botón derecho seleccionar <Opciones de ventana...>. Ahí introduciremos los valores de la variable “*Alfabetización*” para los que vamos a usar el modelo lineal, borrando previamente los que aparecen por defecto.

Copiar en la tabla los valores de las variables “*Alfabetización*” y “*Mortalidad infantil*” correspondientes a los países indicados (buscarlos en el fichero de datos). En este caso, se trata de ver si la calidad de la estimación que proporciona el modelo es buena o mala.

País	Alfabetización Buscado en tabla	Mort. Inf. Real Buscado en tabla	Mort.Inf. estimada Valores Predichos	¿Buena estimación?
Camerún	63,0	69,0	66,122	Buena
España	97,0	5,0	21,398	Mala
Indonesia	84,0	39,0	38,4983	Muy Buena

Si tenemos datos de dos países para los que nos dan el valor de la alfabetización:

- País A: alfabetización del 5%
- País B: Alfabetización del 90%

¿Qué valores tendría la variable mortalidad infantil para ellos, usando el modelo de regresión obtenido? ¿Estas estimaciones serían fiables?

Alfabetización X	Mort. Inf. Real Pronosticado Y	¿Buena estimación?
5,0	30,6059	Posiblemente , Mala
90,0	142,416	Posiblemente muy mala ,país desarrollado con muchas muertes

2.2. ESTUDIO PARA DETERMINAR LA INFLUENCIA DE LA ALFABETIZACIÓN EN EL PRODUCTO INTERIOR BRUTO PER CÁPITA

Se quiere estudiar ahora la influencia de la alfabetización de un país (“*Alfabetización*”) en su producto interior bruto per cápita (“*PIBpc*”).


2.2.1. Ajuste y análisis de un modelo lineal

Ajustar un modelo lineal que permita medir la influencia de la alfabetización de un país (“*Alfabetización*”) en su producto interior bruto per cápita (“*PIBpc*”).

Importante ¿Cuál es la variable dependiente (Y) y cuál es la variable independiente (X)?

→ la regresión trata de encontrar una función que permita "explicar" una variable (generalmente Y) en términos de otra variable (X), por lo que X será Alfabetización y la variable Y será PIBpc.

Copiar el gráfico y los resultados. Para aumentar la claridad del gráfico, pinchar en su panel con el botón derecho, seleccionar <Opciones de ventana...> y desactivar <Límites de predicción> y <Límites de Confianza>.



Interpretar el coeficiente de correlación lineal y su signo. Interpretar también el coeficiente de determinación:

Si $r > 0$, la dependencia lineal es positiva. Indica que cuando X crece, la Y crece. Esto significa que cuando una variable aumenta, la otra también tiende a aumentar. En este caso: a mayor tasa de alfabetización, mayor es el PIB per cápita. Como el valor de 0,553 está alejado de 1 (y por debajo de 0,75), podemos concluir que la relación lineal entre la alfabetización y el PIB per cápita es **moderada o débil**.


R^2 es también llamado **coeficiente de determinación**, Esto significa que solo el 30,62% de la variabilidad del PIB per cápita queda explicada por el nivel de alfabetización utilizando este modelo. Al estar más cerca de 0 que de 100%, indica que es un mal ajuste y que el PIB depende en gran medida de otros muchos factores.

A la vista del diagrama de dispersión y del coeficiente de determinación, ¿es el modelo lineal el más adecuado para explicar la relación entre ambas variables? ¿Qué tipo de función podría encajar mejor para explicar el producto interior bruto per cápita en términos de la alfabetización?

El modelo lineal no es el adecuado. Ya que su R^2 es muy bajo de 30,6229 % mucho menos de el **75% necesario para considerar el ajuste como bueno.**

¿Por qué? La nube de puntos no forma una diagonal recta. El PIB se mantiene muy bajito y concentrado hasta llegar casi al 80% de alfabetización, y a partir de ahí se dispara hacia arriba abriéndose muchísimo. La línea azul (la recta) intenta pasar por el medio, pero no logra captar esa forma curva y deja muchísimos puntos fuera.

¿Qué función encajaría mejor? Sin duda, un modelo exponencial, describe exactamente esa misma curva de "despegue", donde los valores crecen de forma multiplicativa y acelerada al final



2.2.1. Ensayo de otros modelos de ajuste


Se trata de estudiar otros modelos de regresión para explicar la relación entre las variables “*Alfabetización*” y “*PIBpc*”. En la tabla que está más bajo proponemos probar cuatro modelos que, por la forma del diagrama de dispersión, podrían encajar con la estructura de los datos. Para ello:

Usar el menú **Relacionar > Modelos Reg. Simple > Regresión simple...** Elegir la variable dependiente (Y) y la variable independiente (X). En el cuadro de diálogo **<Opciones Regresión Simple>**, elegir sucesivamente los modelos propuestos en la tabla.

En el cuadro de diálogo **<Tablas y Gráficos>**, marcar **<Resumen del análisis>**, **<Pronósticos>** y **<Gráfico del Modelo Ajustado>**.

Para cada modelo: dibujar el diagrama de dispersión, obtener la ecuación del modelo y su coeficiente de determinación R^2 :

Modelo	Ecuación del modelo ajustado	R^2
X-cuadrada: $Y = a + bX^2$	PIBpc = - 2460,98 + 1,58902 * (Alfabetización^2)	33,6345%
Exponencial: $Y = e^{a+b \cdot X}$	PIBpc = exp (5,61594 + 0,0354618 * Alfabetización)	49,6293%
Y-Inverso: $Y = \frac{1}{a+b \cdot X}$	PIBpc = 1 / (0,00143693 - 0,0000131551 * Alfabetización)	47,135%



¿Qué modelos de los tres propuestos mejoran el ajuste lineal? ¿Con cuál nos quedaríamos?

Viendo que la R^2 de nuestro modelo lineal inicial era de 30,6229 %, los modelos que mejoran el ajuste lineal serán la raíz cuadrada de X con un R^2 de 33,6345%, el Exponencial con un R^2 de 49,6293%, y el Y – inversa con un R^2 de 47,135%. Es decir todos los modelos probados mejoran el lineal.

El que mejor se ajusta será el modelo **Exponencial** al ser su R^2 49,6293%, nos quedaremos por tanto con este.

¿Se puede explicar que estos modelos mejoren al lineal considerando el contenido de las variables en estudio?

La alfabetización hace tope en el 100%, pero la riqueza (PIB) puede seguir creciendo sin límite. Una línea recta asume que ambos crecen a ritmo constante para siempre, lo cual es imposible. Subir del 20% al 30% de alfabetización mejora un poco la economía. Pero cuando rozas el 100%, tienes una sociedad lista para la tecnología y la innovación. Ahí el PIB no solo suma, se multiplica y se dispara hacia arriba.

Por eso una curva (como la exponencial o hiperbólica que tienes en los apuntes) es el modelo perfecto: dibuja ese crecimiento plano al principio y la explosión de riqueza al final.

Usar el mejor modelo de regresión de los cuatro modelos propuestos para estimar el “**PIBpc**” en un país cuya “**Alfabetización**” es del 80%:

Alfabetización	PIBpc Predicho	¿Es buena estimación?
80%	2600,6 → Y Inversa	Mala estimación
80%	4688,57 → Exponencial	Muy buena
80%	7708,72 → X cuadrada	Mala estimación

¿Estimación? → Se ha comprobado con Omán país que con un 80% de alfabetización tiene un PIBpc de 8200\$ y con Madagascar que con la misma alfabetización obtienen solo 820\$, siendo la media entre ellos de 4500\$, valor a que deben acercarse.

2.2. MODELOS DE REGRESIÓN POLINOMIAL


Siguiendo con el estudio de cómo influye la alfabetización de un país (“**Alfabetización**”) en su producto interior bruto per cápita (“**PIBpc**”), vamos a ver si usar un polinomio puede mejorar los ajustes obtenidos en el apartado anterior. → X e Y iguales que antes.

Usar el menú **Relacionar > Regresión polinomial**. Hay que elegir adecuadamente qué variable es la variable dependiente y cuál es la variable independiente y el grado del polinomio. En el cuadro de diálogo <Tablas y Gráficos>, marcar <Resumen del análisis>, <Pronósticos> y <Gráfico del Modelo Ajustado>.

Probar con polinomios de grado 2 y 3 y comentar las diferencias en los ajustes. Seleccionar sucesivamente los dos modelos indicados, observar cuál se ajusta mejor, obtener la ecuación del modelo y su coeficiente de determinación:

Modelo	Ecuación del modelo ajustado	R ²
Polinomio grado 2: $Y = a + bX + cX^2$	$PIBpc = 11064,5 - 443,215 * Alfabetización + 4,78129 * Alfabetización^2$	36,1385%
Polinomio grado 3: $Y = a + bX + cX^2 + dX^3$	$PIBpc = -11790,1 + 830,214 * Alfabetización - 16,5131 * Alfabetización^2 + 0,109478 * Alfabetización^3$	37,7368%

Dibujar los diagramas de dispersión para cada modelo



¿Alguno de los modelos polinómicos mejoran el ajuste respecto a lo obtenido en el apartado 2.2.2? ¿Con qué modelo nos quedaríamos finalmente para explicar cómo influye la alfabetización de un país (“Alfabetización”) en su producto interior bruto per cápita (“PIBpc”)?

Vale veamos las R^2 de dispersiones para los polinomios de grado 2 y grado 3 , son respectivamente de 36,1385% para la de grado 2 y de 37,7368% para la de grado 3 , estos resultados no mejoran el mejor de los resultados obtenidos en el apartado 2.2.2 , así pues nos quedaríamos con el resultado mejor de dicho apartado para explicar cómo influye la alfabetización de un país (“Alfabetización”) en su producto interior bruto per cápita (“PIBpc”) que es el **MODELO EXPONENCIAL**.

